

# PONTIA WORLD

## RECONOCIMIENTO DE EMOCIONES

Sistema avanzado de análisis de datos para la detección y clasificación de emociones en parques temáticos.



# Objetivos

## OBJETIVO GENERAL

Analizar los datos generales generados en Pontia World para detectar patrones en las emociones y usar esa información para mejorar la experiencia de los clientes y la rentabilidad del negocio.

## OBJETIVOS ESPECÍFICOS

### OBJETIVO 1

Desarrollar un proceso de limpieza y acondicionamiento de datos completo.

### OBJETIVO 2

Diseñar e implementar un modelo de base de datos relacional que organice la información para facilitar consultas.

### OBJETIVO 3

Desarrollar, entrenar y comparar diferentes modelos para clasificar emociones y una propuesta de IA Generativa.

### OBJETIVO 4

Generar un dashboard de insights para presentar los datos y conclusiones.

# Metodología

Partiendo de los datos iniciales no estructurados, se identificaron y corrigieron diversos problemas de calidad:


- ★ **FORMATO DE DATOS**  
Limpieza y transformación de datos en tablas.
- ★ **VALORES NEGATIVOS**  
Tiempo de espera, costes y duraciones negativas transformados a valores positivos.
- ★ **CAMPO ID VISITANTE INCONSISTENTE**  
Se creó un nuevo campo id\_visitante a partir de los datos de procedencia, duración y día de visita.
- ★ **VALORES EXTREMOS EN DURACIÓN**  
Visitas con duración superior a 9 horas imputadas con la duración media de 350 minutos.
- ★ **VALORES ATÍPICOS EN COSTES**  
Tickets con valores muy bajos revisados por tipo de entrada.





# Análisis exploratorio

Se realizaron visualizaciones como mapamundi de distribución geográfica de visitantes, gráficos de número de visitantes por atracción, distribución de entradas y duraciones medias.



Distribución de Visitantes por Procedencia



# Base de datos

## PROCESO PREPARACIÓN SQL

### ★ LIMPIEZA Y TRANSFORMACIÓN

Limpieza y transformación de datos para cargarlos en SQL.

### ★ SOLUCIÓN DE ERRORES TÉCNICOS

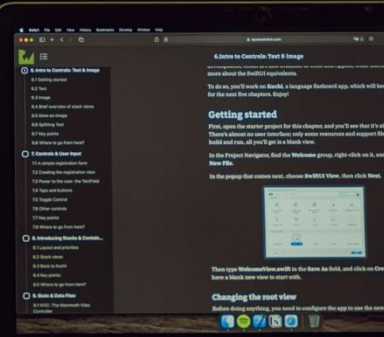

Solución de errores de codificación + validación de tipos + problemas de carga de datos.

### ★ DEFINICIÓN DE REGLAS DE NEGOCIO

Definición de reglas de negocio para imputar valores anómalos (duración > 540min = 350 min, fast pass comprados con > 3 días de antelación = Pase rápido erróneo).

### ★ PREPARACIÓN FINAL

Uso de tablas con datos limpios para la realización de consultas de KPIs.



# Modelo relacional

## Modelo de datos


Se diseñó un modelo relacional que conecta las fuentes de datos y tablas principales para facilitar consultas analíticas.

## Sistema de Rankings

Se implementó un sistema de ranking para manejar empates en los datos y obtener una mejor visión de conjunto.

## Conclusiones

- ★ Los visitantes subían como máximo a 7 atracciones, y como mínimo a 1.
- ★ La emoción más frecuente es "feliz" para todas las atracciones.
- ★ Todas las atracciones tienen prácticamente la misma media de valoración (5/10).



# Insights destacados

- ★ El 90,74% de los visitantes se han montado en solo una atracción durante su estancia en el parque.
- ★ La media de valoraciones no varía significativamente por cada país (5/10).
- ★ Las entradas tienen el mismo precio independientemente de la antelación de su compra (15-18€).
- ★ El tiempo de espera no afecta positiva o negativamente a las valoraciones.
- ★ El tiempo de espera es prácticamente igual para todas las atracciones (12-13 min).



# Detección de emociones

## OBJETIVO

Desarrollar un sistema que clasifique 7 emociones a partir de imágenes faciales pequeñas en blanco y negro.

ANGRY

DISGUST

FEAR

HAPPY

NEUTRAL

SURPRISE

SAD

## PREPARACIÓN DE DATOS

- ✓ División de datos para entrenar el modelo y probarlo.
- ✓ Aumentación moderada de imágenes para incrementar el número de fotos por emoción (rotación, traslación, flip, zoom).
- ✓ Normalización de las imágenes para agilizar el procesamiento en el modelo.


## MÉTRICAS PRINCIPALES Y CRITERIOS DE EVALUACIÓN

### ★ KPI principal — Macro-F1

Promedio de la capacidad de acierto y fallos por clase.

### ★ KPI de referencia — Accuracy

Número de aciertos del modelo general, sin diferenciar por clases.





# Evolución de los modelos

## DEL PUNTO DE PARTIDA AL MEJOR MODELO

### ★ FASE 0 – Aprendizaje a partir de un modelo ya entrenado

Empezamos con un modelo ya entrenado (MobileNet), pero no se adaptó bien a nuestras imágenes pequeñas. Resultado: ~48 % de aciertos.

### ★ FASE 1 – Nuestro primer modelo propio

Creamos desde cero una red sencilla, como una versión básica de la anterior. Esto permitió que el modelo “aprendiera por sí mismo” las emociones. Resultado: mejoró hasta un 54 % de aciertos pero fallaba en sad/angry.

### ★ FASE 2 – Un modelo más profundo y equilibrado

Añadimos más capas, técnicas para que no se “atasque” y equilibramos las clases para que todas las emociones tuvieran el mismo peso. Resultado: un 63 % de aciertos y empezó a distinguir mejor entre emociones similares.

### ★ FASE 3 – Combinamos lo mejor de dos mundos

Usamos la red como base y añadimos un clasificador especial para emociones difíciles. Resultado: mejor precisión en angry/fear/sad.

### ★ FASE 4 – El modelo final: combinación inteligente

Creamos un ensamble, es decir, una fusión suave entre el modelo general y el especializado. Así aprovechamos la fuerza de ambos: uno más equilibrado, el otro más preciso. Resultado final: 65 % de aciertos y 62,4 % de equilibrio entre clases — el mejor rendimiento global del proyecto.

| Fase | Modelo    | Accuracy | Macro-F1 |
|------|-----------|----------|----------|
| 0    | Base      | 0,48     | 0,48     |
| 1    | Simple    | 0,54     | 0,50     |
| 2    | Profunda  | 0,63     | 0,61     |
| 3    | Combinado | 0,64     | 0,61     |
| 4    | Ensamble  | 0,65     | 0,62     |

# Conclusión y modelo final

## FUNCIONAMIENTO DEL MODELO ELEGIDO

- 1 Recibe la imagen en tamaño pequeño y en blanco y negro (para quedarse con las formas y gestos importantes).
- 2 Una red neuronal (CNN) actúa como extractor de rasgos: cejas, ojos, comisuras, arrugas. De ahí saca un resumen numérico que luego usamos en nuestro modelo
- 3 Se combinan dos opiniones independientes: generalista (probabilidad por emoción) y especialista (para casos confusos).
- 4 Combinamos dos modelos: uno más general y otro más especializado. El general tiene más peso (75 %) y el especializado aporta un 25 %, de modo que el resultado final aprovecha lo mejor de ambos.
- 5 Se elige la emoción con mayor probabilidad y se muestra también un nivel de confianza.



# ¿Es bueno el modelo?



# ¿Es bueno el modelo?



**MIEDO**



**ENFADO**



**ENFADO**



# Nuestro modelo


## ANGRY (ENFADO)

Aproximadamente 65 % de aciertos.

## FEAR (MIEDO)

Aproximadamente 55 % de aciertos.

👉 Es decir, nuestro modelo reconoce bien el enfado en unos 2 de cada 3 casos, y el miedo en algo más de 1 de cada 2



# Viabilidad de las métricas

## ★ SUPERACIÓN DEL NIVEL DE AZAR

El modelo del Proyecto Júpiter (64.54% Accuracy) supera significativamente el nivel de azar para 7 emociones (14.29% Accuracy), siendo aproximadamente 4.5 veces más preciso que una predicción aleatoria.

## ★ RENDIMIENTO COMPARATIVO CON HUMANOS (FER2013)

En el dataset FER2013, el rendimiento humano estimado es de ~65.5% Accuracy. El modelo del Proyecto Júpiter (64.54% Accuracy) se encuentra muy cerca de este demostrando una capacidad competitiva.


## ★ CONTEXTO DE COMPLEJIDAD

Estudios muestran que el rendimiento humano en tareas de reconocimiento de emociones puede variar (41%-72% Accuracy) y ser inferior en contextos más complejos o con mayor número de emociones.

## ★ VIABILIDAD Y POTENCIAL

Las métricas obtenidas demuestran que el modelo es viable y robusto para la clasificación de emociones, ofreciendo una base sólida para la toma de decisiones estratégicas en PontIA World.

Comparación de Rendimiento: Modelo vs. Azar vs. Humano





# IA generativa

## RESUMEN

### ★ PROBLEMA

Valoraciones bajas en atracciones (media de 5 sobre 10).

### ★ OBJETIVO

Mejorar la experiencia y valoraciones de los visitantes.

### ★ SOLUCIÓN

IA generativa para personalización de la experiencia en tiempo real.


## CASOS DE USO

- ✓ Itinerario y recomendaciones personalizadas e info tiempos de espera aproximado para las atracciones en tiempo real.
- ✓ Asistente o chatbot para incidencias y dudas del usuario.
- ✓ Diseño adaptativo y escalable de experiencias basado en emociones y datos recopilados.

## BENEFICIOS ESPERADOS

- ✓ Fiabilidad y trazabilidad de datos automatizada.
- ✓ Mejora de valoraciones (objetivo: subir de 5-7 sobre 10 en aprox. 6 meses tras despliegue).
- ✓ Propuesta de valor diferencial frente a competencia.

# Dashboard interactivo





# Conclusiones

- ✓ Los visitantes no se van del satisfechos con la experiencia: sus valoraciones son bajas y muchos solo se suben a una atracción antes de marcharse.
- ✓ No hay una estrategia clara de precios, lo que hace que algunos pases no resulten atractivos y la recaudación sea baja.
- ✓ El parque recibe pocos visitantes y no logra generar un impacto positivo que los incentive a repetir la experiencia.

# Trabajo a futuro

- ★ Reforzar la experiencia del visitante, aprovechando los resultados emocionales para detectar qué zonas o atracciones generan más disfrute o frustración.
- ★ Ajustar la estrategia de precios según el tipo de pase y antelación de compra.
- ★ Diseñar nuevas experiencias basadas en emociones positivas —más momentos “wow” que fomenten la fidelidad.
- ★ Integrar el modelo de emociones en tiempo real.
- ★ Predecir satisfacción y anticipar caídas de afluencia.
- ★ Implementar tablas estáticas en SQL para almacenar métricas clave reduciendo memoria de trabajo.





# ¡GRACIAS!